

Projet de module deep learning en Science de Données et Intelligence Artificielle

*Filière : Master
SDIA*



réalisé par:
ALOUANE Kawter
Baida Aya
LAKHTIRI Salma

Présenté le 12/06/2026

Sous l'encadrement du :
Prof.Youness Abouqora

Année universitaire 2025/2026



Contexte et Problématique



Etat de l'art



Implementation



Résultats & Évaluation



Conclusion & Perspectives

CONTEXTE ET PROBLÉMATIQUE

**100 000+****nouveaux sites par mois**

Des pages frauduleuses imitant banques et réseaux sociaux créées chaque mois.

APWG 2024

**50 Mds \$****de pertes financières annuelles**

Vol de données bancaires et d'identifiants causant des pertes mondiales massives.

FBI IC3 2023

**36 %****des violations de données**

Le phishing reste le vecteur d'attaque numéro 1 dans les cyberincidents mondiaux.

Verizon DBIR 2024

**Comment ça fonctionne ?****1**

Copie visuelle d'un site légitime (banque, PayPal)

**2**

URL trompeuse pour induire en erreur ex. secure-paypal-login.com

**3**

La victime saisit ses identifiants sur la fausse page

**Pourquoi les solutions classiques échouent ?**

Listes noires : obsolètes en quelques heures après la mise en ligne d'un nouveau site.



Règles manuelles : facilement contournées par les attaquants qui adaptent leurs techniques.



→ **Le Deep Learning est nécessaire** pour détecter automatiquement les nouvelles variantes et s'adapter en continu.



Question centrale de recherche

Dans quelle mesure les approches de Deep Learning permettent-elles de détecter automatiquement les sites de phishing de manière efficace et interprétable ?

01



Concevoir le modèle CNN

Modèle CNN 1D multi-entrées
URLs + features HTML.

02



Évaluer les performances

Accuracy, F1-Score et AUC-ROC
sur dataset équilibré.

03



Visualiser les résultats

Interface web interactive
pour les prédictions et métriques.

04



Interpréter avec SHAP

Analyse de l'importance des
features pour expliquer les
décisions du modèle.

Etat de l'art



RNN / LSTM

Analyse séquentielle
caractère par caractère.

- Capture les dépendances longues
- Adapté aux données temporelles
- Historique important en NLP

 Usage typique

Analyse de texte, séries temporelles, langage naturel



CNN + RNN Hybride

Combinaison de l'extraction locale (CNN) et du contexte global (RNN).

- Représentation multi-niveaux
- Capture motifs locaux et dépendances globales
- Architecture flexible

 Usage typique

Classification de texte complexe, analyse séquentielle avancée



Transformers / BERT

Mécanisme d'attention permettant une compréhension contextuelle globale.

- Excellentes performances NLP
- Représentations riches du texte
- Large écosystème de modèles pré-entraînés

 Usage typique

Classification, traduction, compréhension de texte



CNN 1D

Convolutions appliquées directement aux séquences de caractères.

- Détection efficace de motifs locaux
- Architecture légère
- Entraînement rapide

 Usage typique

Classification d'URLs, détection de phishing, analyse de séquences courtes



Analyse comparative

Chaque approche possède des avantages spécifiques. Afin de sélectionner la plus adaptée à notre contexte (URLs courtes, contraintes temps réel et besoin d'interprétabilité), nous avons ensuite réalisé une analyse comparative.




Prochaine slide
Pourquoi CNN 1D ?


✕ APPROCHES ÉCARTÉES

**RNN / LSTM**

lent, vanishing gradient,
incompatible

**CNN + RNN hybride**

sur-dimensionné pour
URLs courtes, difficile
à interpréter

**Transformers / BERT**

coûteux (GPU),
boîte noire totale,
inadapté temps réel



VS

★ NOTRE CHOIX

**CNN 1D**

Entraînement rapide



Architecture multi-entrées
URL + HTML



Interprétabilité des prédictions
via SHAP



Validé dans la littérature :
URLNet, Kim (2014)



Implementation

	Dataset 1	Dataset 2
 Fichier	phishing_site_urls.csv	dataset_small.csv
 Taille	549 346 URLs	58 645 entrées
 Entrée	URL brute (texte)	111 features numériques
 Classes	bad : 156 422 / good : 392 924	phishing : 30 647 / légitime : 27 998



Modèle CNN — URL

URL tokenisée (niveau caractère)



Modèle CNN — HTML

Contenu HTML tokenisé



Entraînement du modèle

Hyperparamètres

Learning rate	0.001
Batch size	64
Époques	20
Optimiseur	Adam
Fonction de perte	binary_crossentropy
Métrique	Accuracy

Découpage des données



● Train ● Test ● Validation

Les données sont réparties de manière stratifiée pour préserver la distribution des classes.

Processus d'entraînement



Compilation

Adam + binary_crossentropy
+ accuracy



Entraînement

model.fit() sur données train,
validation en temps réel



Évaluation

Accuracy, F1-Score et
AUC-ROC sur le jeu de test



Sauvegarde

Modèle .h5 + tokenizer .pkl
dans models/

Résultats & Évaluation

Détection HTML / Fichiers

Importer un fichier

 page_t...gitime.html  4.3KB +

☒ Afficher SHAP pour l'URL la plus suspecte

☒ Afficher SHAP pour le contenu HTML

Prédire fichier

URL trouvées : 16

Taux d'URL de phishing : 43,75 %

HTML

URL

Saisir une URL


http://bank-login-verification.test


☒ Afficher l'explication SHAP


Predire URL

Resultat: Phishing

Probabilite phishing: 0.9834









URL


HTML





URL

HTML



The background features a light gray field with abstract geometric elements. In the top-left corner, there is a series of concentric, wavy lines in a light blue-gray color. In the top-right corner, a solid teal-colored shape, resembling a quarter-circle or a large arc, is partially visible. The bottom-left and bottom-right corners are decorated with complex, interconnected line patterns that form a grid-like structure, with some nodes highlighted in a darker blue. The central text is a large, bold, dark blue font.

Conclusion & Perspectives

Conclusion

Ce travail a permis de développer une solution intelligente et automatisée pour la détection des sites de phishing, reposant sur des techniques de Deep Learning. Le système proposé combine des modèles d'apprentissage profond avec des outils d'explicabilité et une interface intuitive, offrant ainsi une réponse concrète et accessible à une menace cybersécuritaire en constante évolution.

Perspectives

- ✔ Intégrer l'analyse d'autres types de fichiers tels que les scripts JavaScript et les feuilles de style CSS afin d'enrichir les signaux de détection
- ✔ Enrichir le dataset en intégrant des flux de menaces en temps réel pour mieux couvrir les nouvelles techniques de phishing
- ✔ Déployer le système en API REST afin de l'intégrer dans des navigateurs web ou des solutions de cybersécurité existantes
- ✔ Explorer des modèles plus avancés tels que DistilBERT fine-tuné, tout en maintenant des contraintes de temps réel et d'interprétabilité

**Merci pour votre
attention**

